

Predicción de Precios de SUVs a partir de Datos Reales del Mercado con Modelos de Machine Learning

Agustin Ezequiel Amblard*

Alejo Zimmermann†

**aamblard@udesa.edu.ar*

†*azimmermann@udesa.edu.ar*

Abstract

En este trabajo abordamos el problema de estimar el precio de vehículos tipo SUV en el mercado automotor argentino, utilizando técnicas de aprendizaje automático supervisado sobre datos reales. A partir de un conjunto de datos compuesto por características técnicas, estéticas y comerciales de miles de vehículos, entrenamos y comparamos múltiples modelos de regresión, incluyendo regresión lineal, Random Forest, XGBoost y redes neuronales (MLP). Se realiza un análisis exhaustivo del preprocesamiento de datos, tratamiento de valores faltantes, codificación de variables categóricas e ingeniería de features. Además, como extensión del problema, se estudió el efecto de los años de uso, el kilometraje y si tiene cámara de retroceso sobre el precio de un auto, que confirmó nuestra suposición acerca del efecto de estas categorías sobre el precio. Nuestros resultados muestran que los modelos no lineales superan ampliamente a la regresión lineal en capacidad predictiva, alcanzando valores de *RMSE* de 4706.78.

I. INTRODUCCIÓN

El mercado de vehículos tipo SUV ha crecido de manera sostenida en los últimos años, consolidándose como uno de los segmentos más relevantes dentro de la industria automotriz nacional. Dado su amplio rango de precios, versiones, configuraciones técnicas y estilos, contar con herramientas que permitan estimar de forma precisa el valor de un SUV resulta de gran utilidad tanto para fabricantes, concesionarias y plataformas de publicación, como para usuarios finales.

El objetivo de este trabajo es construir modelos de aprendizaje automático capaces de predecir el precio de un SUV a partir de sus características técnicas (por ejemplo, tipo de motor, potencia o tracción), estéticas (color, versión, año) y comerciales (kilometraje, tipo de vendedor, presencia de cámara de retroceso, entre otras). Para ello se parte de un conjunto de datos reales, obtenido de publicaciones de SUVs disponibles en Mercado Libre argentina.

Como entrada, el modelo recibe variables numéricas y categóricas que describen cada vehículo. La salida esperada es una estimación numérica del precio en dolares. Se entrenan y comparan múltiples modelos supervisados, incluyendo regresión lineal, Random Forest, XGBoost y redes neuronales tipo perceptrón multicapa (MLP), evaluando su rendimiento mediante métricas estándar como RMSE y R^2 .

Además de la tarea principal de predicción, se implementa una extensión orientada a detectar oportunidades de compra, identificando publicaciones cuyo precio se encuentra significativamente por debajo del valor estimado por el modelo. Esto permite demostrar cómo los modelos predictivos pueden ser utilizados para tareas derivadas, agregando valor estratégico al análisis de datos del sector automotor.

II. CONJUNTO DE DATOS Y CARACTERÍSTICAS

El conjunto de datos utilizado fue obtenido a partir de publicaciones en línea de vehículos tipo SUV ofrecidos en la empresa de comercio en línea argentina Mercado Libre. El dataset estaba compuesto por mas de 18000 publicaciones. Cada una de ellas representa una unidad publicada, acompañada por una serie de variables que describen sus características técnicas, estéticas y comerciales. El dataset sin preprocesamiento tenia como features Marca, Modelo, Año, Versión, Color, Tipo de combustible, Puertas, Transmisión, Motor, Tipo de carrocería, Con cámara de retroceso, Kilómetros, Título, Moneda, Descripción y Tipo de vendedor. En base a eso se procesó el dataset en diversas variables numéricas y categóricas

Entre las variables numéricas procesadas se encuentran: *Precio*, *Kilómetros*, *Año de fabricación*, *Potencia (HP)* y *Cilindrada del motor*. Las variables categóricas incluyen: *Marca*, *Modelo*, *Versión*, *Color*, *Tipo de combustible*, *Tipo de transmisión*, *Tipo de vendedor*, *Tracción (4x4)* y presencia de *cámara de retroceso*. Estas variables fueron obtenidas mediante un preprocesamiento exhaustivo.

Luego se solucionó el problema de los valores faltantes en variables clave como el año o la cilindrada del motor. Para ello se desarrollaron funciones específicas basadas en subconjuntos con características similares. Dependiendo del caso y de la correlación de la variable a imputar con las demás, el subconjunto elegido fue más general o se pudo hilar mas fino. Asimismo, las variables categóricas fueron transformadas mediante codificación ordinal o one-hot encoding, dependiendo de su cardinalidad y relevancia para los modelos. Las variables numéricas fueron normalizadas mediante *StandardScaler*, a fin de mejorar el comportamiento de los modelos basados en gradiente.

El paso de variables de texto (como Marca, Modelo Versión) a variables numéricas se hizo mediante una asignación de un numero específico para cada una de ellas. De esta forma, se concluye con una base de datos limpia, sin valores nulos y numérica.

III. METODOLOGÍA

El objetivo del presente trabajo fue entrenar modelos de regresión supervisada para estimar el precio de SUVs a partir de características disponibles en publicaciones online. A continuación se explica el paso a paso empleado para estudiar el caso previsto:

A. Preprocesamiento

Se implementó un proceso de limpieza y preparación de datos que incluyó múltiples etapas, diseñadas para maximizar la calidad del conjunto sin sacrificar representatividad. El objetivo fue preservar la mayor cantidad de registros posibles, evitando eliminaciones masivas y extrayendo valor incluso de entradas incompletas o ruidosas.

- **Curado de entradas:** Se aplicó una limpieza general sobre las variables textuales que contenían información redundante o mal segmentada. Se detectó que en la columna de *Versión* se acumulaba información relativa a otras variables técnicas, como el tipo de tracción, la cilindrada del motor o el tipo de combustible, por lo que se procedió a extraer estos datos y reubicarlos en columnas específicas. También se corrigieron errores ortográficos, se normalizó el formato y se agruparon variantes similares mediante técnicas de clustering semántico.
- **Ingeniería de variables (feature engineering):** A partir de las variables depuradas, se generaron nuevas columnas derivadas como *Caballos de fuerza (HP)* y *Tracción*, todas las cuales aportan información técnica clave sobre el vehículo. Esta estrategia permitió enriquecer la matriz de predictores sin requerir datos adicionales externos.
- **División del conjunto de datos:** El conjunto completo se dividió en un 80 % para entrenamiento y validación, y un 20 % para evaluación final. Dentro del bloque de entrenamiento, se utilizó un 80 % para el entrenamiento propiamente dicho y un 20 % como conjunto de validación. Las métricas reportadas en este informe se basan únicamente en el conjunto de evaluación, nunca utilizado durante el entrenamiento ni en el ajuste de hiperparámetros para evitar data leakage.
- **Limpieza de valores atípicos (outliers):** Específicamente para la variable de *Kilómetros* se aplicó el criterio estadístico de rango intercuartílico (IQR) formando rangos razonables de kilometraje en base a la antigüedad de los vehículos. Se definieron como outliers los valores que se encontraban por fuera del rango:

$$[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$$

donde Q_1 y Q_3 son el primer y tercer cuartil respectivamente, e $IQR = Q_3 - Q_1$. Los valores fuera de ese rango fueron imputados mediante una moda. Para variables categóricas como *Marca*, *Modelo* y *Versión*, se construyeron diccionarios de valores válidos a partir del conjunto de entrenamiento. Las entradas que no coincidían con estos diccionarios fueron marcadas como ausentes para su posterior imputación siguiendo criterios de subconjuntos similares.

- **Imputación de valores faltantes:** Se diseñaron estrategias específicas para cada variable. En lugar de aplicar imputaciones globales, se utilizó un enfoque jerárquico, comenzando por agrupamientos granulares (como combinaciones de *Marca-Modelo-Versión*) y luego, en caso de insuficiencia de datos, retrocediendo a niveles más generales (como solo *Marca* o solo *Modelo*). Se priorizó mantener el registro siempre que se contara con un contexto razonable para inferir el dato faltante. En casos complejos como el de la columna *Año*, se utilizaron modelos predictivos (por ejemplo, *Random Forest*) entrenados sobre subconjuntos con características coincidentes.
- **Codificación de variables categóricas:** Las columnas ordinales o jerárquicas, como *Marca*, *Modelo* y *Versión*, fueron transformadas mediante codificación ordinal. En cambio, aquellas con naturaleza nominal o binaria, como *Con cámara de retroceso*, *Tipo de tracción*, *Tipo de combustible* y *Tipo de vendedor*, se codificaron mediante *one-hot encoding*, garantizando así su adecuada interpretación por parte de modelos lineales o basados en distancias.
- **Escalado de variables numéricas:** Para algunos modelos, se aplicó normalización estándar utilizando la función *StandardScaler* de la librería de sklearn sobre las variables continuas. Esta técnica transforma las variables para que tengan media cero y desviación estándar uno, lo cual resulta especialmente útil en modelos sensibles a la escala.

B. Modelos utilizados

Se seleccionaron cinco algoritmos de regresión supervisada para abordar la tarea de estimación de precios. La elección de estos modelos respondió a criterios de diversidad metodológica, robustez ante distintos tipos de datos, y su capacidad para capturar relaciones tanto lineales como no lineales. A continuación se describen en detalle:

- **Regresión lineal:** utilizada como modelo base debido a su simplicidad, bajo costo computacional e interpretabilidad directa. Supone una relación lineal entre las variables independientes y la variable objetivo. El modelo estima los coeficientes mediante minimización del error cuadrático medio (MSE), y cada coeficiente puede interpretarse como el efecto marginal de su variable asociada. Su fórmula general es:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \varepsilon$$

donde β_i representa el coeficiente estimado para cada variable x_i . Es sensible a la presencia de outliers.

- **Árbol de decisión (Decision Tree):** este modelo divide recursivamente el espacio de variables en regiones homogéneas minimizando una función de costo. Cada nodo representa una condición de división, y las hojas contienen predicciones promedio. No requiere escalado de variables ni codificación especial para variables categóricas. Su principal fortaleza es la interpretabilidad del flujo de decisiones y su capacidad de capturar interacciones no lineales. Funciona especialmente bien en presencia de relaciones jerárquicas o umbrales.
- **Random Forest Regressor:** ensamble de múltiples árboles de decisión entrenados sobre subconjuntos aleatorios de instancias y de variables. Las predicciones se obtienen promediando las salidas de los árboles individuales, lo que reduce la varianza del modelo sin aumentar el sesgo. Este método mejora la generalización y es menos propenso al sobreajuste que un solo árbol. También permite medir la importancia relativa de cada variable predictora a través del promedio de la reducción de impureza.
- **XGBoost Regressor:** técnica de *gradient boosting* optimizada para alto rendimiento. Agrega modelos de forma secuencial, donde cada nuevo busca corregir los errores del modelo anterior utilizando el gradiente de una función de pérdida. Se destaca por su eficiencia computacional que ayuda a evitar el sobreajuste.
- **MLP Regressor (Perceptrón Multicapa):** red neuronal compuesta por capas ocultas densamente conectadas. Cada neurona aplica una transformación no lineal y permite aprender representaciones complejas de los datos. El modelo se entrena mediante retropropagación del error y descenso del gradiente estocástico. Se aplicaron técnicas de *early stopping* y búsqueda en grilla para ajustar hiperparámetros clave como el número de capas, neuronas por capa, tasa de aprendizaje y regularización. Aunque es más costoso computacionalmente, su capacidad de aproximar funciones arbitrarias lo hace valioso en problemas no lineales de alta dimensión.

Todos los modelos fueron implementados con el uso de bibliotecas especializadas de Python como **scikit-learn** para regresión lineal, árboles y MLP, y **xgboost** para boosting de gradiente.

La búsqueda de hiperparámetros en los modelos no lineales se realizó mediante *GridSearchCV*, optimizando el *Root Mean Squared Error (RMSE)* sobre un conjunto de validación. Esta métrica fue seleccionada por su sensibilidad a errores grandes, lo que es relevante en contextos donde los desvíos importantes en la predicción de precios tienen un impacto significativo.

El RMSE se define como:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

donde $\hat{y}_i$ representa la predicción del modelo para la observación i , y_i es el valor real y n es el número total de observaciones. Esta medida penaliza con mayor severidad los errores grandes, lo cual resulta útil cuando se desea evitar subestimaciones o sobreestimaciones significativas del precio del vehículo.

C. Evaluación

Se utilizaron como métricas principales el *Root Mean Squared Error (RMSE)* y el coeficiente de determinación R^2 . Finalmente, los modelos entrenados fueron evaluados sobre un conjunto de prueba independiente, y se seleccionó el mejor modelo en base al menor RMSE en validation.

Adicionalmente, se utilizaron herramientas como **MLflow** para el registro y comparación de experimentos, incluyendo métricas, hiperparámetros y modelos entrenados, facilitando así la trazabilidad del proceso y la elección del modelo final.

IV. RESULTADOS, EXPERIMENTOS Y DISCUSIÓN

Para comparar el desempeño de los distintos modelos entrenados, se utilizó como conjunto de evaluación final un subconjunto del dataset reservado exclusivamente para prueba. Las métricas utilizadas fueron el *Root Mean Squared Error (RMSE)* y el coeficiente de determinación R^2 .

Hiperparámetros seleccionados

Los hiperparámetros que mejor se adaptaron a cada modelo fueron los siguientes:

- **Regresión Lineal:**
 - Sin hiperparámetros relevantes (modelo base sin regularización).
- **Árbol de Decisión (Decision Tree Regressor):**
 - `max_depth = 21`
- **Random Forest Regressor:**

- n_estimators = 50
- max_depth = 11
- **XGBoost Regressor:**
 - n_estimators = 300
 - max_depth = 5
 - learning_rate = 0.1
 - subsample = 0.8
- **MLP Regressor (Perceptrón Multicapa):**
 - hidden_layer_sizes = (50, 50)
 - activation = 'relu'
 - early_stopping = True

En la Tabla I se presentan los resultados obtenidos por cada modelo sobre el conjunto de prueba. La regresión lineal, como era esperable, presentó el peor desempeño, dado que no logra capturar la complejidad no lineal del problema. Por el contrario, los modelos basados en árboles, especialmente XGBoost, mostraron una capacidad predictiva muy superior, alcanzando valores de R^2 por encima de 0.92 y RMSE notablemente inferiores en validación. Esto también se mantuvo mientras se entrenaban los modelos.

TABLE I
COMPARACIÓN DE DESEMPEÑO ENTRE MODELOS (CONJUNTO DE PRUEBA)

Modelo	RMSE (USD)	R^2
Regresión Lineal	10733.72	0.5933
Árbol de Decisión	6636.97	0.8445
Random Forest	5203.08	0.9044
XGBoost	4706.78	0.9218
MLP Regressor	7650.13	0.7934

A partir de la tabla, se observa que los modelos de ensamble (Random Forest y XGBoost) superan ampliamente tanto a la regresión lineal como al árbol de decisión individual y al MLP. XGBoost logra el menor error absoluto y el mayor R^2 , lo que indica que es el modelo que mejor logra explicar la variabilidad del precio a partir de las variables disponibles. Random Forest también obtiene un desempeño muy alto, aunque levemente inferior a XGBoost, mostrando la robustez de los métodos de ensamble para este tipo de datos tabulares.

El árbol de decisión simple mejora considerablemente respecto a la regresión lineal, pero sufre de mayor varianza y menor capacidad de generalización, lo que se refleja en un R^2 intermedio. El MLP, a pesar de su flexibilidad, no logra superar a los modelos de árboles, posiblemente debido a la naturaleza tabular y la cantidad de datos disponibles, donde los métodos basados en árboles suelen ser más eficientes y requieren menos ajuste fino.

En cuanto a los tiempos de entrenamiento, la regresión lineal y el árbol de decisión fueron los más rápidos, completando el ajuste en segundos. Random Forest y XGBoost requirieron tiempos de entrenamiento mayores, del orden de varios minutos, especialmente XGBoost debido a la cantidad de árboles y la optimización de hiperparámetros. El MLP también presentó tiempos de entrenamiento elevados, ya que el ajuste de redes neuronales implica múltiples épocas y validación temprana. Sin embargo, el incremento en tiempo de cómputo de los modelos de ensamble se justifica ampliamente por la mejora significativa en el desempeño predictivo.

En síntesis, los resultados muestran que para problemas de regresión sobre datos tabulares, los modelos de ensamble basados en árboles, y en particular XGBoost, ofrecen la mejor combinación de precisión y robustez, aunque a costa de un mayor tiempo de entrenamiento.

Como extensión del trabajo, se analizó el efecto de algunas variables clave sobre el precio estimado de los vehículos. En particular, se estudió la influencia del año de fabricación, el kilometraje, la presencia de cámara de retroceso, la potencia del motor (medida en caballos de fuerza) y el tipo de transmisión (manual o automática). Este análisis permitió complementar la interpretación de los modelos entrenados.




Fig. 1. Matriz de correlación entre variables clave: Año, Kilómetros, HP, Cámara de retroceso y tipo de transmisión.

La figura 1 muestra eso mismo. Se puede ver como cada una de esas variables afecta al precio del auto. En primer lugar, el año tiene una correlación positiva con el precio lo cual se puede ver en el dataset. Los autos mas nuevos tienden a ser mas caros que los usados. Esto puede ser por los avances tecnologicos como una camara de retroceso (lo cual tambien tiene una correlacion positiva con el precio). Los kilometros tambien se relacionan con el precio. Una cantidad alta de kilometros suele indicar un desgaste alto del auto. Lo cual baja el precio. Por eso tiene correlación negativa. Las variables de caballos de potencia (HP) y tipo de transmisión (is_manual) son variables que se relacionan con lo mecánico del auto. HP tiene correlación positiva y muy alta, indicando que la cantidad de caballos de fuerza del motor es crucial para la elección del precio. Por el otro lado, la transmisión tiene correlación negativa mostrando que los autos manuales tienden a ser mas baratos. Las cajas automaticas suben el precio de los autos.

V. CONCLUSIÓN

En este trabajo se abordó la predicción de precios de SUVs en el mercado argentino mediante modelos de aprendizaje automático aplicados a datos reales. Se realizó un preprocesamiento cuidadoso, incluyendo limpieza, imputación de valores faltantes y transformación de variables, lo que permitió obtener un conjunto de datos apto para el entrenamiento de modelos robustos.

Si bien el conjunto de datos utilizado permitió entrenar modelos robustos y alcanzar métricas de predicción satisfactorias, presenta varias limitaciones que condicionan el alcance y la generalización de los resultados.

Una de las principales barreras fue que los datos fueron generados manualmente por usuarios, sin una estandarización previa en categorías clave como la *Versión*, variable de alto impacto en el valor final de un vehículo. Al tratarse de datos desordenados, con errores ortográficos frecuentes y una alta proporción de valores nulos, fue necesario inferir gran parte de la información faltante mediante imputación. Este proceso, aunque cuidadosamente diseñado, puede introducir sesgos y afectar la precisión de las predicciones finales.

Los resultados demostraron que los modelos no lineales, en particular XGBoost y Random Forest, ofrecen un desempeño significativamente superior a la regresión lineal, logrando valores de R^2 mayores a 0.92 y menores errores de predicción. El análisis de importancia de variables confirmó que el año, el kilometraje, la potencia y la transmisión son los principales determinantes del precio.

En conclusión, la aplicación de machine learning en este contexto permite no solo mejorar la estimación de precios, sino también aportar herramientas de valor para la toma de decisiones de usuarios y empresas en el rubro automotriz.